

# מעבדה בעיבוד אותות

## פזיולוגיים

### הנדסה ביורפואית

מגישים :

דן טורצקי  
סול אמרה

תאריך :

23.12.2022

## תוכן עניינים:

1	תקציר:	3
2	ניסויים:	4
2.1	ניסוי 1: סגמנטציה של שני מצבים: עיניים פקוחות \ סגורות	4
2.1.1	היפותזה:	4
2.1.2	מתודולוגיה:	4
2.1.3	תוצאות:	4
2.1.4	מסקנות:	8
2.2	ניסוי 2: שערך EP ע"י מיצוע	10
2.2.1	היפותזה:	10
2.2.2	מתודולוגיה:	10
2.2.3	תוצאות:	10
2.2.4	מסקנות:	15
2.3	ניסוי 3: סינון אדפטיבי	17
2.3.1	היפותזה:	17
2.3.2	מתודולוגיה:	17
2.3.3	תוצאות:	17
2.3.4	מסקנות:	20
3	מסקנות כלליות	21
4	מקורות	22
5	נספחים	23

## 1 תקציר:

במעבדה זו חקרנו ומימשנו אלגוריתמים שלמדנו בקורסים קודמים על גבי אותות EEG שרשמנו. בניסוי הראשון בדקנו את יכולת ההפרדה של האלגוריתם בין גלי המוח. ראינו כי הצלחנו למצוא מסנן בעל יכולת הפרדה טובה יותר כך שטווח תגדרי המעבר נמוך וכי ככל שסדר המסנן גדל התגובה לתדר יותר חדה ולכן תוצאת הסינון טובה יותר. בנוסף, קיבלנו כי אין הבדל מובהק סטטיסטית בין פתיחת וסגירת עיניים בניגוד לספרות ושיערנו שתוצאה זו נובעת מרעש והסחות דעת של הנבדק. בנוסף, ראינו כי הזזת העיניים מוסיפה רעש לאות. בניסוי השני חקרנו מיצוע הומוגני ואקספוננציאלי למציאת VEP באותות מסונתזים ואמיתיים. ראינו כי עבור אותות מסונתזים ניתן להשתמש במיצוע הומוגני. בנוסף, עבור סנתוז אות המורכב משני סוגי Eps שונים ראינו כי ככל שהחפיפה ביניהם גבוהה יותר מיצוע אקספוננציאלי עם מקדם דעיכה גדול יותר הוביל לשגיאה קטנה יותר בתנאי שישנה דעיכה של ה-EP. יתר על כן, ראינו כי עבור אות EEG שנמדד במעבדה לאחר המיצוע התקבל אות הדומה לתוצאה שהתקבלה מהאות המסונתז. עם זאת, באותות אלה ישנם רעשים שעלולים לפגוע ביכולת ההפרדה. בניסוי השלישי, השתמשנו באלגוריתם LMS לסינון רעשי רשת, ECG ו-EOG מאות EEG. התנסינו במציאת גודל הצעד וראינו את חשיבותו בהצלחת האלגוריתם.

## 2 ניסויים:

### 2.1 ניסוי 1: סגמנטציה של שני מצבים: עיניים פקוחות \ סגורות

#### 2.1.1 היפותזה:

כפי שראינו בדוח המכין, גלי אלפא הינם גלים בטווח תדרים של  $8 - 13 [Hz]$  והם מופיעים באמפליטודה הגבוהה ביותר בזמן ערות או ישנוניות עם עיניים עצומות ועוצמתם יורדת עם פתיחת העיניים או שינה. נצפה בניסוי זה לראות את השינויים הנ"ל בעת פתיחת וסגירת העיניים. בנוסף, בעת תזוזת העיניים כאשר הן עצומות נצפה שהתזוזה תוסיף רעש ולכן תפגע ביכולת ההפרדה בין המצבים.

#### 2.1.2 מתודולוגיה:

מכשור וציוד: אלקטרודות, תוכנת BSL 4.0 M36 התומכת במערכת biopac.

מהלך הניסוי: מיקמנו את האלקטרודות במקומות הבאים:



איור 1: מיקום האלקטרודות [1]

תחילה כילנו את המערכת כאשר הנבדק נינוח ועם עיניים עצומות לקבלת אות יחסית שקט. לאחר מכן, ביצענו מעבר בין שלושה מצבים שונים:

1. עיניים פקוחות, ללא הזזת העיניים וללא מצמוץ.
2. עיניים עצומות, ללא הזזת העיניים.
3. עיניים עצומות, הזזת העיניים.

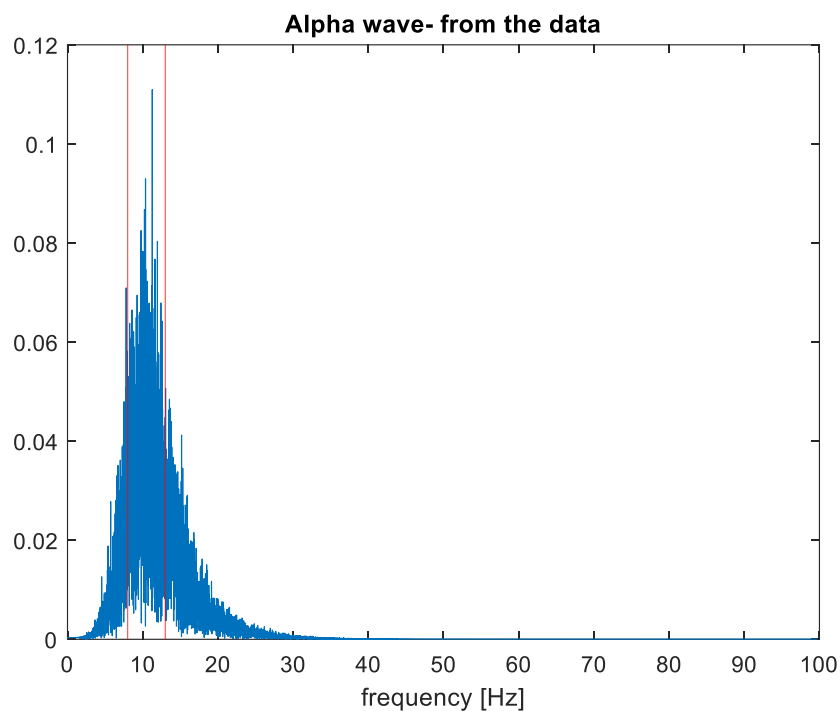
את ההקלטה ביצענו למשך 2 דקות: 80 שניות ראשונות מתוכן 10 שניות במצב 2 ולאחר מכן 10 שניות במצב 1 לסירוגין. לאחר מכן 40 שניות מתוכן 10 שניות במצב 3 ולאחר מכן 10 שניות במצב 1 לסירוגין. כמו כן, ביצענו סימון על ידי F4 בעת פתיחת העיניים ו F5 בסגירתן. שמרנו את ההקלטה ואת הסימונים.

#### 2.1.3 תוצאות:

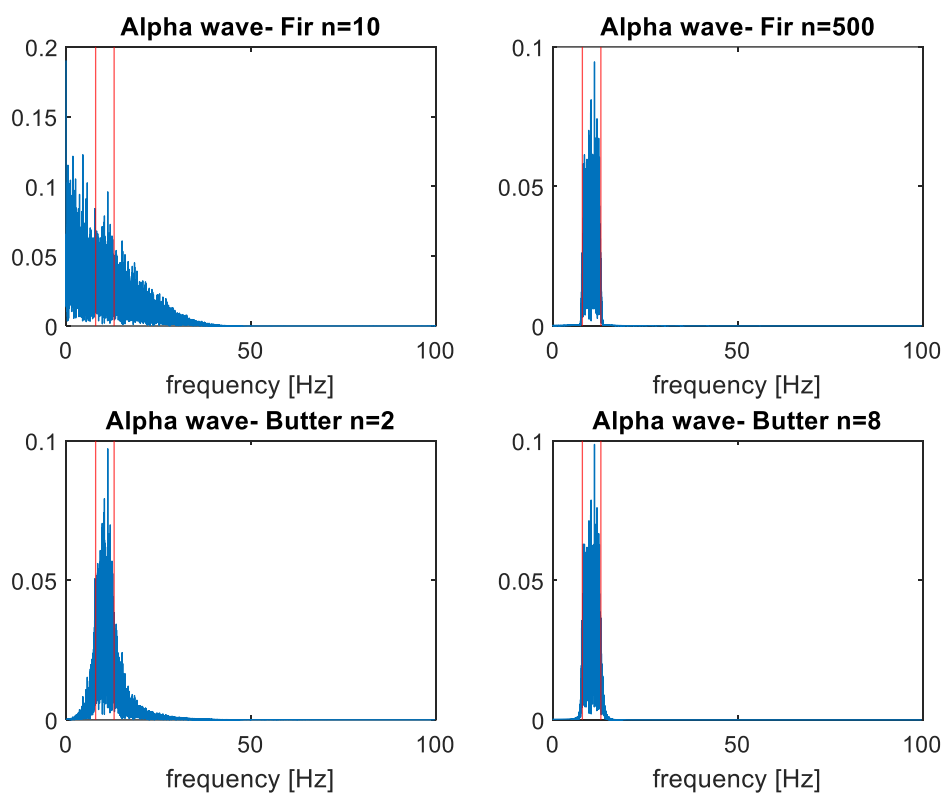
התוצאות לניסוי זה נלקחו מנדב אמיתי ויובל כסיף (באישור).

1.1

1.1.1



איור 2: התמרת FFT של גל האלפא כפי שהתוכנה סיננה



איור 3: התמרת FFT של גל האלפא לאחר סינון אות ה-EEG המלא בעזרת מסנני BPF

מהשוואה בין איור 2 ל3 ניתן לראות כי הן עבור מסנן FIR מסדר 500 והן עבור מסנן BUTTERWORTH מסדר 8 קיבלנו תוצאת סינון טובה יותר מאשר האלגוריתם של התוכנה כיוון

שיש פחות זליגה של תדרים מעבר לתחום המבוקש,  $8 - 13 [Hz]$ . כמו כן, ניתן לראות כי עבור מסנני BUTTERWORTH ניתן להגיע לתוצאה טובה עבור סדר מסנן קטן בהרבה מזה של מסנן FIR אך בשניהם ראינו כי טיב הסינון גדל עם עליית סדר המסנן. מסקנה זו תואמת לתיאוריה שלמדנו כיוון שככל שסדר המסנן עולה, התגובה לתדר יותר חדה וכתוצאה מכך יהיו פחות תדרים בתחום המעבר.

לאחר מכן, בעזרת שיטת  $t$ -test בדקנו מתי השגיאה שונה באופן מובהק מ-0. תוצאות המובהקות שקיבלנו:

טבלה 1: חישוב המובהקות

$p$ -value : FIR 10	$p$ -value : FIR 500	$p$ -value : butterworth 2	$p$ -value : butterworth 8
$6.0259 \cdot 10^{-101}$	0.9639	0.9614	0.9608

מטבלה זו ניתן לראות כי רק עבור מסנן FIR מסדר 10 קיבלנו שהשגיאה שונה מ-0 באופן מובהק. עבור המסננים האחרים קיבלנו שהמובהקות גדולה מ-0.05 כלומר השגיאה איננה שונה מ-0, ולכן ניתן להסיק כי עבור מסננים אלה קיבלנו תוצאה טובה. תוצאה זו צפויה מתוך התבוננות באיור 3, שכן המסנן הראשון איננו נמצא בטווח ערכים הרצוי לעומת המסננים האחרים שמביאים שגיאה קטנה יותר.

### 1.1.2

טבלה 2: מקסימום הקורלציה

$p$ -value : FIR 10	$p$ -value : FIR 500	$p$ -value : butterworth 2	$p$ -value : butterworth 8
$1.3293 \cdot 10^4$ $n = 23940$	$7.9418 \cdot 10^3$ $n = 23695$	$9.8987 \cdot 10^3$ $n = 23926$	$8.0628 \cdot 10^3$ $n = 23868$

כאשר אורך הסיגנל הינו  $n=23926$ . ניתן לראות כי עבור המסנן השני והשלישי קיבלנו את התוצאה הצפויה והיא שהמקסימום התקבל בנקודה בה  $n=236926$  כלומר כאשר אין הפרשי זמנים בין שני הסיגנלים. ניתן לראות כי עבור מסנן FIR מסדר 10 קיבלנו את הקורלציה הכי גבוהה אבל קורלציה זו מתקבלת כאשר יש הפרשי זמנים בין הסיגנלים, תוצאה שאיננה הגיונית כיוון שלא נתנו פאזה לאף אחד מהסיגנלים.

1.1.3 בהשוואה לגל האלפא כפי שסווגל מאלגוריתם התוכנה, מסנן butterworth מסדר 2 נותן את התוצאה הטובה ביותר כיוון שהוא בעל שגיאה שאיננה שונה מאפס באופן מובהק והוא מקבל את האוטוקורלציה הגבוהה ביותר כאשר אין הפרשי זמנים בין הסיגנלים. מכאן, שתוצאת סינון זה היא הקרובה ביותר לתוצאת סינון האלגוריתם של התוכנה. עם זאת, אם נסתכל על איור 2 ניתן לראות כי גל האלפא כפי שסווגל מהאלגוריתם של התוכנה הוא בעל תחום מעבר רחב, ונכנסו לגל תדרים נוספים מעבר לתחום הרצוי. בשל כך, ניתן להסיק כי עבור מסנן FIR מסדר 500 קיבלנו גם תחום תדרים מדויק יותר (פחות תדרי מעבר), וגם שגיאה שאיננה שונה מאפס באופן מובהק, בנוסף לקורלציה יחסית גבוהה עם גל האלפא שהתוכנה יצרה ולכן נסיק שעל פי קריטריונים אלה הוא המסנן הטוב ביותר מבין המסננים שבדקנו.

### 1.2

1.2.1 בדקנו בעזרת שיטת  $t$ -test האם השונות של גל האלפא בעת פתיחת וסגירת עיניים שונה באופן מובהק.  $p$ -value שהתקבל הינו 0.0551 כלומר אין מובהקות סטטיסטית. כמו כן, בעזרת

שיטה זו בדקנו בנוסף מתי השונות של גל האלפה שונה באופן מובהק מס עבור כל מקטע בו העיניים עצומות לבין המקטע הבא אחריו עם עיניים פתוחות. תוצאות המובהקות שקיבלנו :

טבלה 3 : מובהקות עבור הבדלים בין פתיחת וסגירת עיניים

0.0008	0.7038	0.1442	0.1915
--------	--------	--------	--------

מטבלה זו ניתן לראות כי יש הבדל מובהק סטטיסטית רק עבור המעבר הראשון בין סגירה לפתיחת עיניים. נסיק כי ייתכן שהמעבר הראשון בוצע ללא הסחות בצורה נכונה ולעומת זאת המעברים האחרים הושפעו מגורמים כמו תזוזה או חשיבה מאומצת.

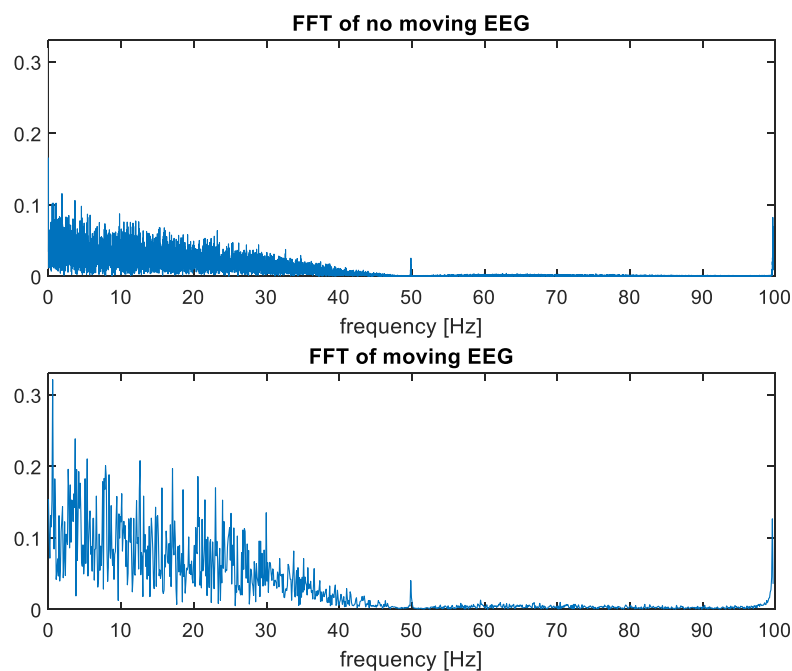
1.2.2 בדקנו בעזרת שיטת  $t$ -test האם השונות של כל אות ה- $EEG$  בעת פתיחת וסגירת עיניים שונה באופן מובהק.  $p$ -value שהתקבל הינו  $3.7186 \cdot 10^{-4}$  כלומר יש מובהקות סטטיסטית. כמו כן, בעזרת שיטה זו בדקנו בנוסף מתי השונות של כל אות ה- $EEG$  שונה באופן מובהק מס עבור כל מקטע בו העיניים עצומות לבין המקטע הבא אחריו עם עיניים פתוחות. תוצאות המובהקות שקיבלנו :

טבלה 4 : מובהקות עבור הבדלים בין פתיחת וסגירת עיניים

0.000	0.0760	0.2263	0.7216
-------	--------	--------	--------

תוצאות טבלה זו זהות לטבלה 3 כיוון שעבור ההבדל בין המקטעים הראשונים קיבלנו מובהקות סטטיסטית ואילו למקטעים האחרים לא.

1.3 בעת תזוזת העיניים : בדקנו בעזרת שיטת  $t$ -test האם הספקטרום של אות ה- $EEG$  בעת הזזת ו לא הזזת העיניים שונה באופן מובהק.  $p$ -value שהתקבל הינו 0 כלומר יש מובהקות סטטיסטית. נדגיש כי השתמשנו במבחן  $vartest$  שבדק האם השונות של שני האותות שונה, כאשר עבור אות ה- $EEG$  בעל ממוצע אפס, אם יש שוני בין אותות הוא יתבטא בשונות שלהם. נסתכל על ה- $FFT$  של האותות :



איור 4 : התמרת ה- $FFT$  של האותות

באיור זה ניתן לראות את ההתמרה של האותות. נבחין כי תוצאה זו תואמת לכך שקיבלנו שיש הבדל מובהק ביניהם, כיוון שניתן לראות שעבור הזות העיניים יש עליה משמעותית בערכי ההתמרה.

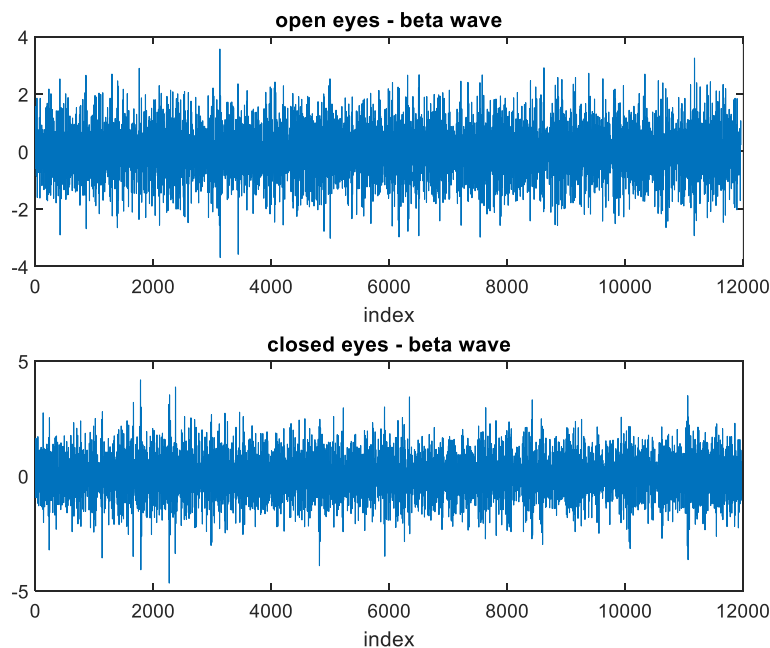
1.4

בניסוי זה ערכי האמפליטודה של גל האלפא נעים בטווח:  $[3.2894, 5.3447 \cdot 10^{-5}]$  ביחידות של  $\mu V$ . האמפליטודה של גל האלפא לפי הספרות הינה משתנה בין נבדק לנבדק אבל לרוב קטנה מ  $50\mu V$ . [2] ניתן לראות כי הטווח שקיבלנו מוכל בטווח זה אך קטן באופן מובהק ממנו, תוצאה הגיונית בשל כך שהספרות מכירה בשוני בטווחים בין אנשים. כמו כן, הנבדק נמדד בנקודת זמן מסוימת ואם נבצע מדידה למשך זמן ארוך יותר ובפעילויות שונות יכול להיות שנקבל טווח אחר.

1.5

נבדוק את האמפליטודה של גל הבטא (תדרים 14-30 Hz) כאשר הנבדק פותח או סוגר את עיניו:

בדקנו בעזרת שיטת  $t$ -test האם יש הבדל מובהק בין האמפליטודה של גל הבטא (תדרים 14-30 Hz) כאשר הנבדק פותח או סוגר את עיניו וה  $p$ -value שהתקבל הינו  $5.0329 \cdot 10^{-5}$  כלומר יש מובהקות סטטיסטית. בנוסף, נסתכל על האמפליטודה של גל הבטא בכל אחד מהמצבים:



איור 5: גל הבטא בעת פתיחת וסגירת העיניים

מאיור זה ניתן לראות את האמפליטודה של גל הבטא. בניגוד להנחה, רואים כי בעת פתיחת העיניים האמפליטודה של גל הבטא  $[-4, 4]$  קטנה מזו של סגירת העיניים  $[-5, 5]$  ובנוסף הוכחנו כי ההבדל מובהק סטטיסטית ולכן טענה זו שגויה ומתקיים ההפך ממנה.

#### 2.1.4 מסקנות:

ראשית בניסוי זה בדקנו את יכולת ההפרדה של האלגוריתם בין גלי המוח. ראינו כי הצלחנו למצוא מסנן FIR מסדר 500 בעל יכולת הפרדה טובה יותר כך שטווח תגדרי המעבר נמוך ובעצם נכנסים פחות תדרים לא רצויים לאות. כמו כן, בהשוואה בין המסננים השונים ראינו כי ככל שסדר המסנן גדל התגובה לתדר יותר חדה ולכן תוצאת הסינון טובה יותר כצפוי. לאחר מכן, בדקנו האם השונות של גל האלפא בין פתיחת וסגירת עיניים שונה באופן מובהק כמו שהיינו



מצפים לפי הספרות. קיבלנו כי אין הבדל מובהק סטטיסטית בין כל האות של הסגירה לבין כל האות של הפתיחה. עם זאת, כאשר בדקנו רק את המעבר בין המצבים קיבלנו כי יש הבדל מובהק בין המעבר מהסגירה הראשונה לפתיחה הראשונה. מכאן שהמעבר בין המצב הראשון הראה שונות מובהקת והאחרים לא ולכן נשער שבמהלך הניסוי התווספו רעשים כמו הסחות דעת שפגעו בתוצאות. בנוסף, בדקנו האם יש הבדל בין הזזת העיניים ללא, וראינו כי ההבדל מובהק. נשער מכך, בדומה להיפותזה, שתזוזת העיניים מוסיפה רעש (ולכן האמפליטודה שלה יותר גבוהה) ומכאן ההבדל. כמו כן, ראינו כי יש הבדל מובהק בין גלי הבטא בסגירת ופתיחת העיניים כאשר האמפליטודה שלהם עולה בסגירתם.

## 2.2 ניסוי 2: שערך EP ע"י מיצוע

### 2.2.1 היפותזה:

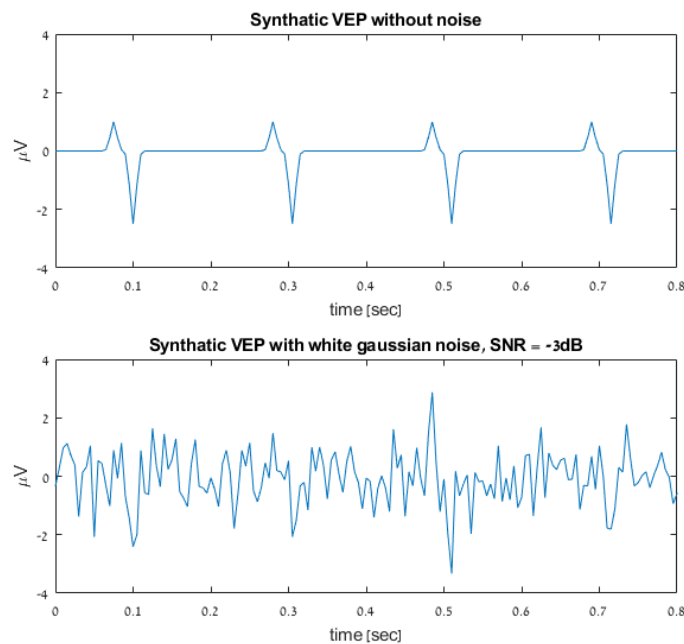
בניסוי זה נבצע מיצוע הומוגני ואקספוננציאלי על אותות מסונתזים ואותות EEG אמיתיים. נצפה כי באותות מסונתזים התוצאה תהיה מתאימה לתאוריה, בעוד באותות אמיתיים נצפה כי התוצאות יהיו יותר מורעשות ופחות חד משמעיות, אך כאלה שניתן לזהות בהם את ה-EPs, גם אם האות אינו חלק כמו בתאוריה.

### 2.2.2 מתודולוגיה:

מכשור וציוד: מחשב, EEG, שלוש אלקטרודות, ערכת biopac הכוללת פנס ותוכנה. מהלך הניסוי: חיברנו לאחד הנסיינים שלוש אלקטרודות בקדמת הראש, קודקוד הראש ואחורי הראש, פתחנו את הניסוי המתאים. כיוונו את הפנס ל-1Hz, ולעבר פניו של הנסיין. במשך שתי דקות נמדד eeg כאשר הפנס מהבהב ועיני הנסיין מתבוננות לכיוון הפנס. לאחר מכן ביצענו לאות זה ולאותות סינטטיים אחרים עיבוד בשיטות Ensemble Averaging כדי לקבל את תגובת ה-VEP.


### 2.2.3 תוצאות:

#### 2.1.1



איור 6: VEP סינטטי עם ובלי רעש גאוזי לבן

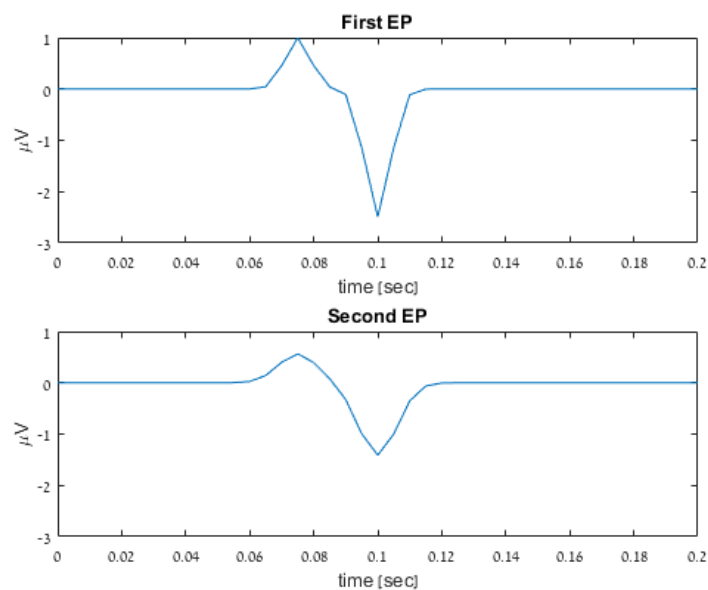
#### 2.1.2



איור 7: EP סינתטי (שמאל למעלה), EP סינתטי לאחר הוספת רעש לבן (ימין למעלה), EP לאחר מיצוע של האות המורעש עם שמונה מקטעים (שמאל למטה), EP לאחר מיצוע של האות המורעש עם 32 מקטעים (ימין למטה)

כפי שניתן לראות באיור, ה-SNR המתקבל משימוש ב-8 מקטעי EP הינו 6.41dB, ומימוש ב-32 מקטעים 12.59dB. ערכים אלה תואמים לתאוריה. כמו כן, האיור ממחיש איך שימוש בכמות גדולה יותר של מקטעים מובילה לסינון טוב יותר.

## 2.2



איור 8: שני סוגי ה-EP שיצרנו


שני סוגי ה- VEP שיצרנו עם פיקים באותם זמנים, והשוני ביניהם הוא בשונות ההתפלגויות ובאמפי שלהם.

### 2.2.1

בחרנו חלונות עם היחסים הבאים בין שני סוגי ה- Eps :

50:0, 35:15, 25:25, 15:35, 0:50

חישבנו את ה- SNR כתלות באלפה עבור כל חלון כזה :




איור 9: SNR כפונקציה בגורם הדעיכה alpha עבור חלונות שונים

ניתן לראות כי ככל שהחפיפה בין סוגי ה- Eps גדולה יותר, כך מקדם הדעיכה האופטימלי גבוה יותר. דבר זה עושה שכל, הרי שככל שהחפיפה קטנה יותר, במקרה שלנו האות יהיה יותר הומוגני ולא משתנה, כך שמיצוע הומוגני יוביל לשגיאה הקטנה ביותר. כאשר אלפה הולך לאפס המיצוע מתקרב למיצוע הומוגני ולכן התוצאות הגיוניות.

## 2.3


### 2.3.1

אות ה – EEG :




איור 10 : אות ה – EEG

ניתן לראות כי רעש רשת רוכב על האות, לכן נסננו :



איור 11 : אות ה – EEG לאחר סינון רעש הרשת

ניתן לראות כי רעש הרשת סונן. ביצוע מיצוע הומוגני על האות נתן :

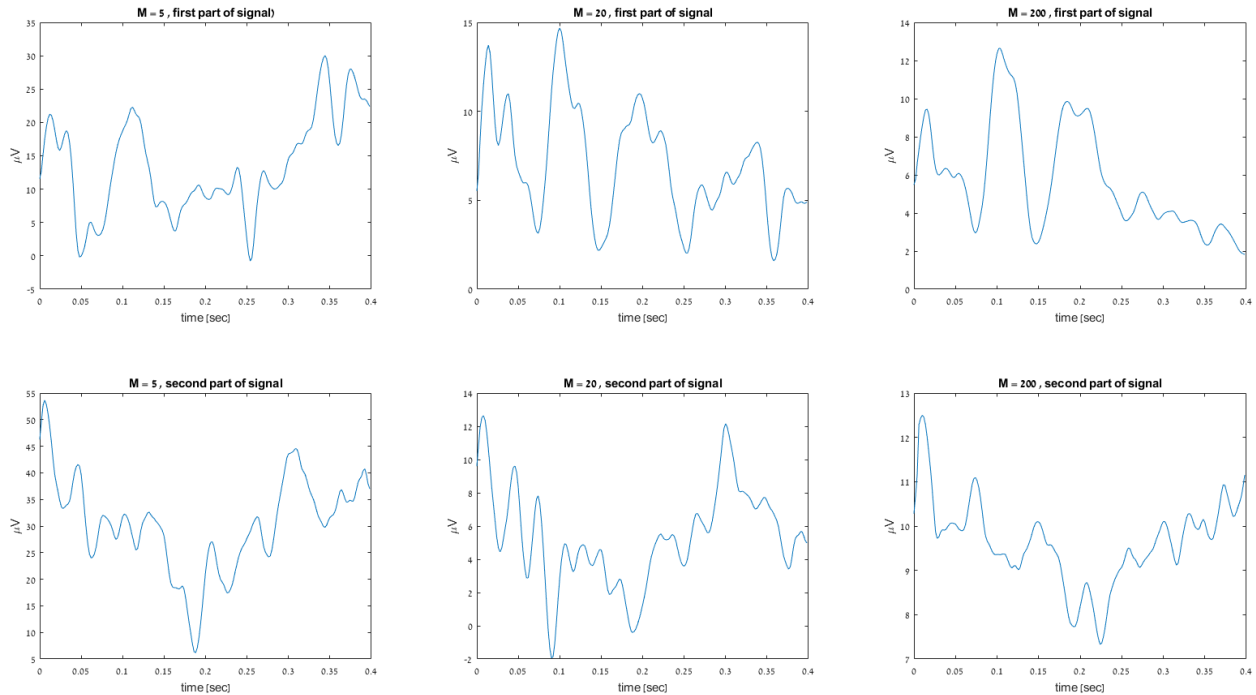


איור 12: מיצוע הומוגני על אות ה- EEG

האות שהתקבל מזכיר מאוד את האות המתקבל באופן תאורטי. הדמיון העקרי הוא בצורת האות - ניתן לראות פיק חיובי ולאחריו פיק שלילי. השוני מהתאוריה מתבטא במספר דברים. נשים לב כי יש היסט DC אך הוא לא נופל מהסינון. כמו כן, ביחס ל- DC של  $15\mu V$  הפיקים מתקבלים בגבהים (בערך מוחלט) דומים, אך זוהי לא סטייה מהותית מהתאוריה.

### 2.3.2

מיצוע על פני האות בחלונות Eps השונים:



איור 13: מיצוע הומוגני של אות ה- EEG. שורה ראשונה מיצוע על חציו הראשון של האות עם כמות של 5, 20, ו- 200 משמאל לימין. שורה שנייה כמו הראשונה על חציו השני של האות

ניתן לראות כי גם במיצוע על פני Eps 200 משני חצאי האות, שני האותות לא תואמים ישירות לתאוריה. עם זאת, במיצוע של Eps 200 על חציו הראשון של האות ניתן לראות פיק שלילי בקירוב ב- 75ms ולאחריו פיק חיובי ב- 100ms. הכיוונים של הפיקים הפוכים למוסכמה אך זה יכול להיות עניין של מדידה. זמנים אלה גם מתאימים לכך שהגירוי ניתן בקצב קבוע מהדגימה הראשונה, כלומר אלו אכן הזמנים שנצפה לראות בהם את התגובה לגירוי. אם כך, נסיק כי הנבדק הסתכל על הפנס בהתחלה.

#### 2.2.4 מסקנות:

בניסוי זה חקרנו מיצוע הומוגני ואקספוננציאלי למציאת VEP באותות מסונתזים ואמיתיים. ראינו כי עבור אותות מסונתזים – המורכבים מ- EP על פי הגדרתו הספרותית ורעש גאוסני לבן – השימוש במיצוע הומוגני (עבור אות עם EP קבוע) מוביל לתוצאות המתאימות לתאוריה. כאשר סנתזנו אות המורכב משני סוגי Eps שונים (שהשוני ביניהם הוא ברוחב הפיקים וגובהם, אך לא בזמן השיא של הפיקים), ראינו כי ככל שהחפיפה ביניהם גבוהה יותר (למשל אות שחצי ממנו מורכב מגירוי מסוג אחד וחציו השני מורכב מהגירוי מהסוג השני), מיצוע אקספוננציאלי עם מקדם דעיכה גדול יותר הוביל לשגיאה קטנה יותר. בהתאמה, ככל שהחפיפה קטנה יותר, כלומר אין שינוי בתגובה לגירוי ה- EP, עדיף להשתמש במקדם דעיכה קטן יותר, כאשר ככל שמתקרבים למקדם דעיכה השווה לאפס, כך המיצוע מתקרב למיצוע הומוגני. לא נסיק כי היינו מקבלים שיפור ב- SNR עבור מקדם דעיכה גדול יותר, אילולא היינו מקטינים גם את אופי התגובה שמגיעה יותר מאוחר באות. זאת כיוון שמקדם הדעיכה גדל, משקל הדגימות האחרונות גדול ממשקל הדגימות הראשונות, ודבר זה מתאים כאשר יש דעיכה בתגובה לגירוי במשך הזמן ככל שניתן יותר גירויים. כאשר השתמשנו בשיטת המיצוע ההומוגני על אות EEG אמיתי שנמדד

במעבדה (לא על ידנו כי האות שלנו כנראה נמדד בצורה שגויה והיה לא שימושי), ראינו כי פרט למספר שינויים אכן יש דמיון בצורה הכללית של האות המתקבל לזו התאורטית. בשימוש בשיטת המיצוע על אות EEG אמיתי נוסף, ראינו כי באותות אמיתיים יכולים להופיע הרבה רעשים שלא ניתן להסיר בשיטת המיצוע וכי יכול להיות יותר מורכב לזהות EP בשיטה זו באות אמיתי, ובכל זאת, לדעתנו ביצענו זיהוי נכון של ה – EP באותות שהתקבלו.



## 2.3 ניסוי 3: סינון אדפטיבי

### 2.3.1 היפותזה:

בניסוי זה נשתמש באלגוריתם LMS כדי לסנן רעשי רשת, ECG ו- EOG מאות EEG. נצפה כי רעש הרשת לא יהיה קשה לסינון היות ודרושים שתי אותות בפאזה שונה ובעלי אותו תדר כדי לזהות סינוס בתדר מסוים ואת האמפ' שלו. סינון שאר האותות יכול להיות מורכב יותר היות ויש לנו רק אות רפרנס אחד של כל אחד מהם, ואות זה יכול להשתנות עם הזמן (כלומר להיות לא סטציונרי), כך שחישוב המשקולות המתאימות לא בהכרח יגיע להתכנסות מתאימה שנכונה לכל מקטעי האות.

### 2.3.2 מתודולוגיה:


מכשור וציוד: מחשב

מהלך הניסוי: בניסוי זה השתמשנו באלגוריתם LMS לשם סינון רעשי רשת, ECG ו- EOG מאות EEG.

### 2.3.3 תוצאות:

3.1

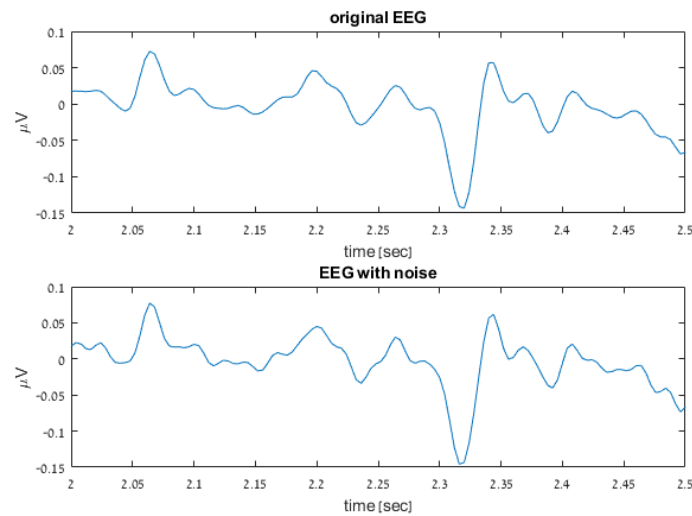
כיוון שהדרישה הייתה לתדר דגימה מקסימלי, נגדיל את תדר הדגימה של כלל האותות לתדר הדגימה של ה- ECG שהינו בעל תדר הדגימה המקסימלי מבין האותות ע"י אינטרפולציה. כיוון שהאותות במקור היו בעלי אותן כמות דגימות, והעלאת קצב הדגימה מוסיפה את מספר הדגימות, כדי שמספר הדגימות של כל האותות הדגומים מחדש יהיה זהה ומקסימלי, דרוש לקצץ אותם לאורך של אות ה- ECG הרי שהוא האות הכי קצר, לא הוספנו לא מידע, ולא ניתן להוסיף לו מידע חדש בתדר דגימה זה, הרי שזה התדר בו הוא נדגם ואין לנו דגימות נוספות שלו. אם כך, התוצאה הינה העלאת קצב הדגימה של כלל האותות ל- 250Hz, ולמספר של 100,000 דגימות:



איור 14: מלמעלה למטה – EEG, ECG, EOG right, EOG left.

ניתן לראות בבירור מאיור זה כיצד ה-ECG וה-EOG מרעישים את אות ה-EEG.

3.3 הצגנו את כלל הרעשים ודנו בהשפעתם הזמנית על אות ה-EEG פרט לרעש הרשת. כעת נציג את השפעתו:



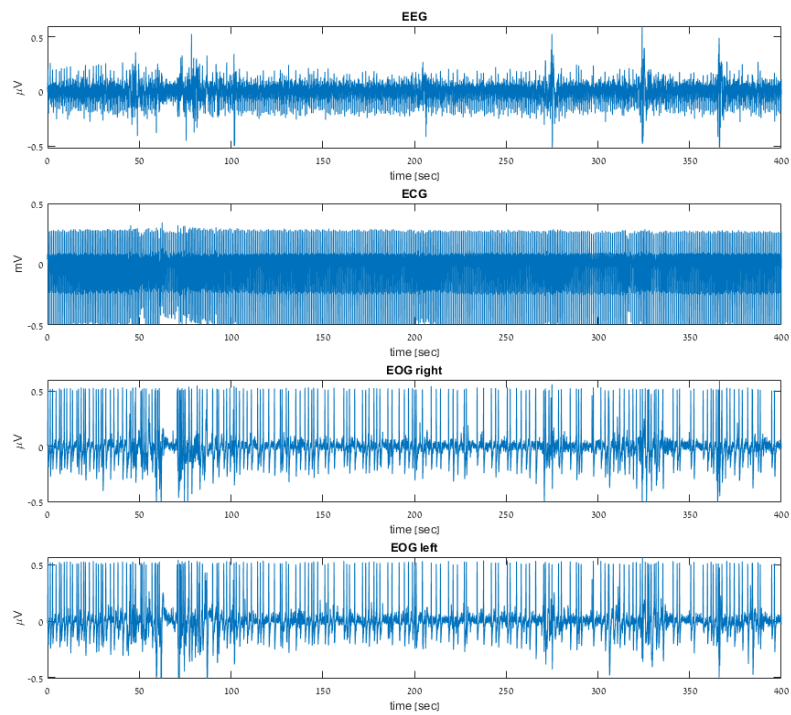
איור 15: אות ה-EEG לפני (למעלה) ואחרי (למטה) הוספת רעש רשת בתדר 50Hz

ניתן לראות בבירור את גל הסינוס הרוכב על האות. כיוון שהאמפ' של הרעש נמוכה יחסית לאמפ' האות, הרעש ניכר בעיקר באזורים בהם הנגזרת קטנה ואין הרבה שינויים באות (למשל בין 0 שניות ל-2 שניות, בין 2.1 ל-2.15 וכ"ו).

### 3.4

ראשית, נציין כי לשם ביצוע ה-LMS לא המרנו את היחידות של אות ה-ECG ל  $\mu V$  היות ואנו מחפשים את המשקולת הרלוונטית לו לשם סינונו, והיא כמובן כזו שיהיה קל יותר למצוא כאשר האמפ' של האות קרובה לזו של אות ה-EEG ממנו אנו מנסים לסנן אותו. תוצאות אלגוריתם ה-LMS:

מהתבוננות באיורים 9, 10 ו-11, והשפעת הרעשים השונים על האות הזמני, ניתן לראות כי רעש הרשת והארטיפקטים העיקריים של אות ה-EOG סוננו בצורה טובה יחסית. מנגד, הפיקים המהירים והגבוהים של אות ה-ECG לא הוסרו. נתבונן באותות הרעש המקוריים לאורך כל ההקלטה:

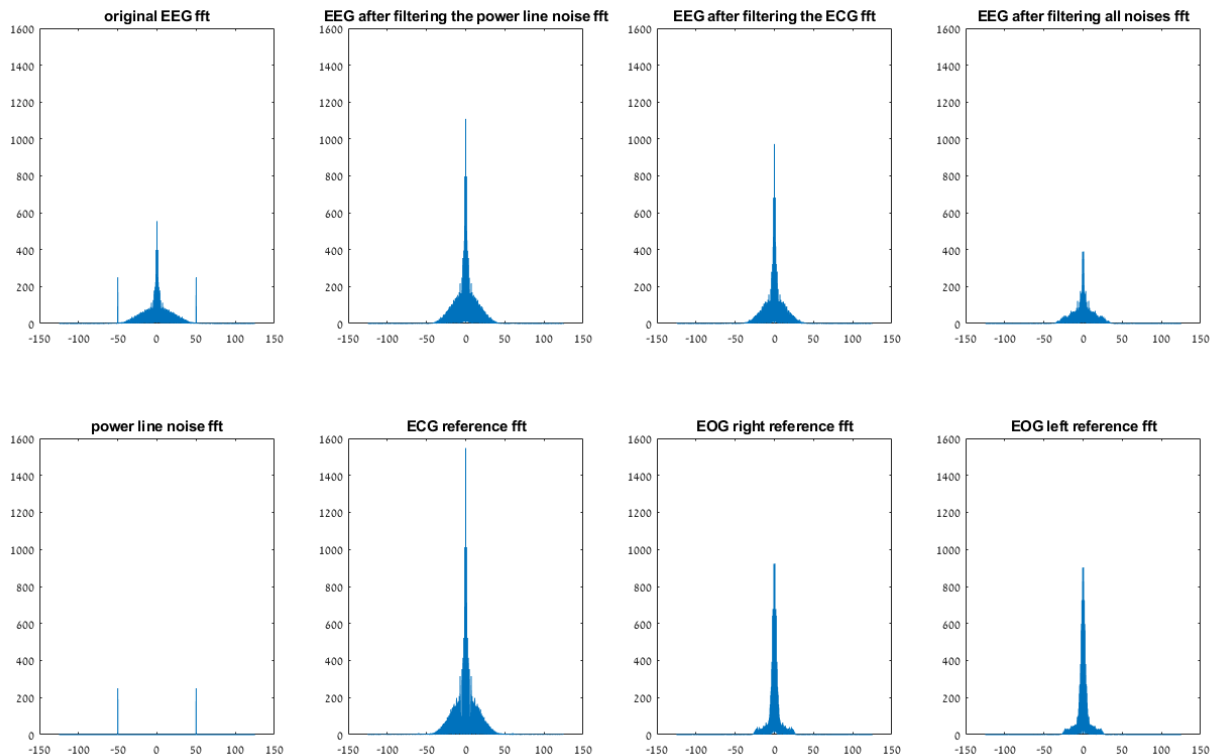


איור 17: האותות כפי שהוצגו באיור 9 לאורך כל המדידה

ניתן לראות כי אותות הרעש המוצגים אינם סטציונריים, וייתכן כי דבר זה מקשה על התכנסות של האלגוריתם לסינון אפקטיבי של הרעש, המתאים לכל מקטעי האות.

3.5.

האותות המסוננים בשלבים השונים בתדר :



איור 18: בשורה הראשונה –  $fft$  של האות הלא מסונן ושלבני סינון השונים (משמאל לימין). בשורה השנייה –  $fft$  של אותות הרעש השונים בהתאם לסדר הסינון משמאל לימין בהתאמה

ניתן לראות כי הסינון הראשון אכן הסיר את רעש הרשת. כיוון שאות ה-ECG ואות ה-EEG לאחר סינון רעש הרשת בעלי צורה דומה בתדר, קשה להעריך את טיב הסינון מגרף של ה- $fft$  שלהם, אך ראינו באות הזמני כי הסינון לא משמעותי. לבסוף, נראה כי אכן יש ירידה מסוימת בתדרים הנמוכים של ה-EOG באות המסונן ובצירוף נראות הסינון באות הזמני ניתן לומר כי סינון ה-EOG יחסית מוצלח. המסקנה הסופית היא שפרט לאות ה-ECG שלא עבר סינון מיטבי, שאר האותות סוננו בצורה מוצלחת יחסית.

### 2.3.4 מסקנות:

בניסוי זה השתמשנו באלגוריתם LMS לסינון רעשי רשת, ECG ו-EOG מאות EEG. הסינון של הרעשים, פרט לאות ה-ECG שלא סונן בצורה מיטבית היו מוצלחים יחסית. אותות ECG ו-EOG יכולים להשתנות בזמן בצורה ניכרת, ולכן סינון שלהם באלגוריתם מתעדכן יכול להיות לא מוצלח בהתאם לכמה האותות אכן משתנים בזמן (למשל, האצת דופק באות ECG). דבר זה יכול להסביר מדוע סינון רעשים אלה לא היה מוצלח מאוד, על אף שאות ה-EOG סונן בצורה טובה יותר מאות ה-ECG. בחירת גודל צעד מתאים לאלגוריתם ה-LMS גם היא חשובה, אך לאחר ניסיונות למציאת גודל הצעד המתאים, גם הגודל בעל ההתכנסות הטובה ביותר לא הניב תוצאות מוצלחות. לדעתנו, הצורה הטובה ביותר בה ניתן לממש אלגוריתם זה כדי לסנן רעשים מסוג זה מתוך EEG היא לדאוג לתנאי תאורה קבועים, לדאוג כי הנבדק יהיה רגוע ככל הניתן, יזוז כמה שפחות, ויתבונן בנקודה מסוימת. המטרה של פעולות אלה הינה לגרום לאותות ה-ECG וה-EOG להיות סטציונרים ככל הניתן וללא הפרעות.

בניסוי הראשון בדקנו את ההבדלים בגלי האלפא בין סגירת ופתיחת עיניים. בניגוד לספרות, לא ראינו הבדל מובהק סטטיסטית ביניהם ולכן שערנו שישנם גורמים שהשפיעו על התוצאות כמו הסחת דעת של הנבדק וכדומה. כמו כן, התנסינו במציאת גל זה מתוך EEG כולו, וראינו שמסנן טוב יהיה בעל תחום מעבר חד כלומר פחות תדרים לא רצויים יעברו וזה יתקבל עבור סדר מסנן גדול יותר. כמו כן, הוכחנו כי בעת תזוזת העיניים מתווספים רעשים כאשר בתדר קיבלנו התמרה גדולה באופן מובהק. בנוסף, ראינו כי טווח האמפליטודה של גל זה הינו רחב ומשתנה בין אדם לאדם, כאשר בניסוי שלנו הטווח היה עד  $3\mu V$ . לאחר מכן, הוכחנו כי האמפליטודה של גל הבטא בעת סגירת העיניים עולה באופן מובהק בניגוד לטענה שהוצגה. בניסוי השני חקרנו מיצוע הומוגני ואקספוננציאלי למציאת VEP באותות מסונתזים ואמיתיים. ראינו כי ניתן להשתמש במיצוע זה עבור אותות מסונתזים ואמיתיים כיוון שהתוצאות שהתקבלו משני האותות היו דומות ולכן שיערנו שתוצאות הסינון טובות. כמו כן, באות אמיתיים ישנם רעשים רבים בניגוד למסונתזים, העלולים לפגוע ביכולתנו לבצע את הסינון. בנוסף, עבור סנתוז של אות משני סוגי EPS שונים ראינו כי ככל שהחפיפה גדולה יותר שימוש במקדם דעיכה גדול יותר יוביל לשגיאה נמוכה יותר (בתנאי שה EP – השני מסוגו בסדר ההופעה דועך במידה מסוימת ביחס ל EP מהסוג הראשון שמופיע). בדומה לכך, ככל שהחפיפה קטנה יותר, עדיף להשתמש במקדם דעיכה קטן יותר, כאשר ככל שמתקרבים למקדם דעיכה השווה לאפס, כך המיצוע מתקרב למיצוע הומוגני. בניסוי האחרון השתמשנו באלגוריתם LMS לסינון רעשי רשת, ECG ו- EOG מאות EEG. הסינון של הרעשים, פרט לאות ה- ECG שלא סונן בצורה מיטבית היו מוצלחים יחסית. בדומה למה שלמדנו בקורסים אחרים, ראינו כי גודל הצעד חשוב ומשפיע על יכולת הסינון כאשר גודל צעד גבוה מידי יוביל להתבדרות ואילו עבור גודל צעד קטן ידרשו איטרציות רבות עד התכנסות. בנוסף, ראינו כי עבור אותות שמשתינים הרבה בזמן אלגוריתם מתעדכן יהיה פחות מוצלח.

- [1] "Biopac MP36 EEG.pdf." Accessed: Dec. 19, 2022. [Online]. Available:  
[https://moodle.bgu.ac.il/moodle/pluginfile.php/3718230/mod\\_resource/content/1/%D7%9E%D7%94%D7%9C%D7%9A%20%D7%A0%D7%99%D7%A1%D7%95%D7%99%2B%D7%9E%D7%A1%D7%9B%D7%9D%20%D7%A2%D7%9D%20Biopac%20MP36%20EEG.pdf](https://moodle.bgu.ac.il/moodle/pluginfile.php/3718230/mod_resource/content/1/%D7%9E%D7%94%D7%9C%D7%9A%20%D7%A0%D7%99%D7%A1%D7%95%D7%99%2B%D7%9E%D7%A1%D7%9B%D7%9D%20%D7%A2%D7%9D%20Biopac%20MP36%20EEG.pdf)
- [2] "EEG- effects of visual activity on alpha waves."  
[https://www.medicine.mcgill.ca/physio/vlab/biomed\\_signals/eeg\\_raw.htm](https://www.medicine.mcgill.ca/physio/vlab/biomed_signals/eeg_raw.htm)  
(accessed Dec. 23, 2022).

```

%% 1
data=readtable('NadavBrain.xlsx');
labels=readtable('Event Summary.xlsx');

EEG=data.EEG;
time=120; %[sec]
L=length(EEG);
Fs=L/time; %[Hz]

f1=8; f2=13; %[Hz]

%% 1.1:
bpf1 = fir1(10,[2*f1/Fs 2*f2/Fs], 'bandpass');
alpha_1=filter(bpf1,1,EEG);

bpf2 = fir1(500,[2*f1/Fs 2*f2/Fs], 'bandpass');
alpha_2=filter(bpf2,1,EEG);

[b3,a3] = butter(2,[2*f1/Fs 2*f2/Fs], 'bandpass');
alpha_3=filter(b3,a3,EEG);

[b4,a4]= butter(8,[2*f1/Fs 2*f2/Fs], 'bandpass');
alpha_4=filter(b4,a4,EEG);

%plot:
f = Fs*(0:(L/2))/L;

Y=fft(data.alpha);P2 = abs(Y/L);P = P2(1:L/2+1); P(2:end-1) = 2*P(2:end-1);
Y=fft(alpha_1);P2 = abs(Y/L);P1 = P2(1:L/2+1); P1(2:end-1) = 2*P1(2:end-1);
Y=fft(alpha_2);P2 = abs(Y/L);P22 = P2(1:L/2+1); P22(2:end-1) = 2*P22(2:end-1);
Y=fft(alpha_3);P2 = abs(Y/L);P3 = P2(1:L/2+1); P3(2:end-1) = 2*P3(2:end-1);
Y=fft(alpha_4);P2 = abs(Y/L);P4 = P2(1:L/2+1); P4(2:end-1) = 2*P4(2:end-1);

figure; plot(f,P); xlabel('frequency [Hz]'); title('Alpha wave- from the data');xline(8,'color','r'); xline(13,'color','r')
figure; subplot(2,2,1);plot(f,P1); xlabel('frequency [Hz]'); title('Alpha wave- Fir n=10'); xline(8,'color','r'); xline(13,'color','r')
subplot(2,2,2);plot(f,P22); xlabel('frequency [Hz]'); title('Alpha wave- Fir n=500');xline(8,'color','r'); xline(13,'color','r')
subplot(2,2,3);plot(f,P3); xlabel('frequency [Hz]'); title('Alpha wave- Butter n=2');xline(8,'color','r'); xline(13,'color','r')
subplot(2,2,4);plot(f,P4); xlabel('frequency [Hz]'); title('Alpha wave- Butter n=8');xline(8,'color','r'); xline(13,'color','r')

%1.1.1:
error1=alpha_1-data.alpha;
error2=alpha_2-data.alpha;
error3=alpha_3-data.alpha;
error4=alpha_4-data.alpha;
[~,pvalue1] = ttest(error1);
[~,pvalue2] = ttest(error2);
[~,pvalue3] = ttest(error3);
[~,pvalue4] = ttest(error4);

%1.1.2:
r1=xcorr(data.alpha,alpha_1);[max_r1,n1]=max(r1);

```

```

r2=xcorr(data.alpha,alpha_2);[max_r2,n2]=max(r2);
r3=xcorr(data.alpha,alpha_3);[max_r3,n3]=max(r3);
r4=xcorr(data.alpha,alpha_4);[max_r4,n4]=max(r4);

%% 1.2:
%not moving the eyes:
t=80; %[sec]
closeeyes=zeros(ceil(10*Fs),4); openeyes=zeros(ceil(10*Fs),4);
closeEEG=zeros(ceil(10*Fs),4); openEEG=zeros(ceil(10*Fs),4);
jc=1; jo=1;
L=length(labels.Time(2:end))-4;
for i=2:L+1
    index=ceil(Fs*labels.Time(i))+1:floor(Fs*labels.Time(i+1))+1;
    if mod(i,2)==0 %becuse the even is "eye closed"
        closeeyes(1:length(index),jc)=data.alpha(index);
        closeEEG(1:length(index),jc)=data.EEG(index);
        jc=jc+1;
    else
        openeyes(1:length(index),jo)=data.alpha(index);
        openEEG(1:length(index),jo)=data.EEG(index);
        jo=jo+1;
    end
end
c=[closeeyes(:,1);closeeyes(:,2);closeeyes(:,3);closeeyes(:,4)];
o=[openeyes(:,1);openeyes(:,2);openeyes(:,3);openeyes(:,4)];
[~,p1]=vartest2(o,c)

[~,p]=vartest2(openeyes,closeeyes)

%1.2.2:
c=[closeEEG(:,1);closeEEG(:,2);closeEEG(:,3);closeEEG(:,4)];
o=[openEEG(:,1);openEEG(:,2);openEEG(:,3);openEEG(:,4)];
[~,p1]=vartest2(o,c)

[~,p]=vartest2(openEEG,closeEEG)

%% 1.3:
%moving the eyes:
t_moving=labels.Time(10);

Nomoving_eyes=data.EEG(1:floor(Fs*labels.Time(i+1)));
moving_eyes=data.EEG(floor(Fs*labels.Time(i+1))+1:end);

Lm=length(moving_eyes); Lno=length(Nomoving_eyes);

Y=fft(moving_eyes);P2 = abs(Y/Lm);Pmove = P2(1:Lm/2+1); Pmove(2:end-1) =
2*Pmove(2:end-1); %FFT of moving eyes
Y=fft(Nomoving_eyes);P2 = abs(Y/Lno);Pnomove = P2(1:Lno/2+1);
Pnomove(2:end-1) = 2*Pnomove(2:end-1); %FFT of no moving eyes

[~,p1]=vartest2(Pmove,Pnomove)

fm= Fs*(0:(Lm/2))/Lm; fno= Fs*(0:(Lno/2))/Lno;
figure
subplot(2,1,1); plot(fno,Pnomove); xlabel('frequency [Hz]'); title('FFT of
no moving EEG'); ylim([ 0 0.33]);
subplot(2,1,2); plot(fm,Pmove); xlabel('frequency [Hz]'); title('FFT of
moving EEG');ylim([ 0 0.33]);

```



```

%% 1.4
alpha=data.alpha;
maxamp=max(alpha)
minamp=min(abs(alpha))

%% 1.5
jc=1; jo=1;
for i=2:12
    index=ceil(Fs*labels.Time(i))+1:floor(Fs*labels.Time(i+1))+1;
    if mod(i,2)==0 %becuse the even is "eye closed"
        closeB(jc:jc+length(index)-1,1)=data.beta(index);
        jc=jc+length(index);
    else
        openB(jo:jo+length(index)-1,1)=data.beta(index);
        jo=jo+length(index);
    end
end

openB_1=data.beta(ceil(Fs*labels.Time(13))+1:end);
openB(jo:jo+length(openB_1)-1,1)=openB_1;

[~,p1]=vartest2(openB,closeB)

figure
subplot(2,1,1);plot(1:length(openB),openB); xlabel('index'); title('open
eyes - beta wave');
subplot(2,1,2);plot(1:length(closeB),closeB); xlabel('index');
title('closed eyes - beta wave');

%% 2.
%% 2.1
%2.1.1
fs = 200; %Hz
t_EP = 0:1/fs:0.2; %[sec] , time vector for a single EP sampled in 200 Hz
N75 = 10^-2*normpdf(t_EP,0.075,0.004); %microV
P100 = -2.5*10^-2*normpdf(t_EP,0.1,0.004); %microV
EP = N75+P100; %signle EP
t = 0:1/fs:(60-29/fs); %60s time vector with fs=200Hz
VEP_1 = repmat(EP,1,floor(length(t)/length(t_EP))); %entire VEP of 60
seconds
EP_pow = 1/length(EP)*sum(EP.^2); %average power of the EP
EP_pow_dB = pow2db(EP_pow); %average power of the EP in dB
noise_pow_dB = pow2db(EP_pow*2); %average power of white noise in dB such
as that the SNR is -3dB
noise = wgn(1,length(VEP_1),noise_pow_dB); %white gaussian noise
noised_VEP_1 = VEP_1 + noise; %VEP signal with added gaussian noise
%plotting the VEP with and without noise
figure; subplot(2,1,1); plot(t,VEP_1); xlabel('time [sec]'); ylabel('\muV')
title('Synthatic VEP without noise'); xlim([0 0.8]); ylim([-4 4])
subplot(2,1,2); plot(t,noised_VEP_1); xlabel('time [sec]'); ylabel('\muV')
title('Synthatic VEP with white gaussian noise, SNR = -3dB'); xlim([0 0.8])

%2.1.2
% Homogenous Ensemble Averaging
% M = 8, 6dB

```

```

noised_VEP_1_resaped = (reshape(noised_VEP_1,[length(EP),
length(VEP_1)/length(EP)]))'; %reshaping the nosied signal such that each
row contains one EP
HEA_M8 = 1/8*sum(noised_VEP_1_resaped(1:8,:)); % homogenous ensemble
averaging with 8 EPs
SNR_M8 = snr(HEA_M8,HEA_M8-EP);

% M = 32, 12dB
HEA_M32 = 1/32*sum(noised_VEP_1_resaped(1:32,:)); % homogenous ensemble
averaging with 8 EPs
SNR_M32 = snr(HEA_M32,HEA_M32-EP);

%plot of the synthesized VEP
figure;
subplot(2,2,1); plot(t_EP,EP); title('original EP'); ylim([-3 3]);
xlabel('time [sec]'); ylabel('\muV')
subplot(2,2,2); plot(t_EP,noised_VEP_1(1:41)); title('EP with gaussian
white noise'); ylim([-3 3]); xlabel('time [sec]'); ylabel('\muV')
subplot(2,2,3); plot(t_EP,HEA_M8); title('HEA with M = 8 , SNR = 6.41');
ylim([-3 3]); xlabel('time [sec]'); ylabel('\muV')
subplot(2,2,4); plot(t_EP,HEA_M32); title('HEA with M = 32 , SNR = 12.59');
ylim([-3 3]); xlabel('time [sec]'); ylabel('\muV')

%% 2.2
N75_2 = 0.85*10^-2*normpdf(t_EP,0.075,0.006); %microV
P100_2 = -2.5*0.85*10^-2*normpdf(t_EP,0.1,0.006); %microV
EP_2 = N75_2+P100_2; %signle EP
figure; subplot(2,1,1); plot(t_EP,EP); ylim([-3 1]); xlabel('time [sec]');
ylabel('\muV'); title('First EP')
subplot(2,1,2); plot(t_EP,EP_2); ylim([-3 1]); xlabel('time [sec]');
ylabel('\muV'); title('Second EP')
VEP_2 = [repmat(EP,1,floor(length(t)/(2*length(t_EP)))) ,...
repmat(EP_2,1,floor(length(t)/(2*length(t_EP))))]; % 30sec first
EP, 30 sec second EP
noised_VEP_2 = VEP_2 + noise; %VEP signal with added gaussian noise

%2.2.1
%Expopnential Averaging

%windows containing different ratios of first and second kind of EP (50:0,
%35:15, 25:25, 15:35, 0:50)
EP_len = length(EP);
num_EPs = length(VEP_2)/EP_len;
Windows = [noised_VEP_2(1:EP_len*50); noised_VEP_2((num_EPs/2-
35)*EP_len:((num_EPs/2+15)*EP_len-1));...
noised_VEP_2((num_EPs/2-25)*EP_len:((num_EPs/2+25)*EP_len-1));
...
noised_VEP_2((num_EPs/2-15)*EP_len:((num_EPs/2+35)*EP_len-1));
...
noised_VEP_2((num_EPs/2)*EP_len:((num_EPs/2+50)*EP_len-1))];

% alpha factors of exponential averaging:
alphas = [0.001, 0.01, 0.3, 0.7, 0.99];

%numbers for plot labels:
labels = [50 35 25 15 0];

% plotting different exponential averaging of windows with different alphas
figure;

```

```

for i = 1:size(Windows,1)
    for j=1:length(alphas)
        VEP = Expo_avrg(Windows(i,:),alphas(j),EP_len);
        subplot(size(Windows,1),length(alphas),(5*(i-1)+j))
        plot(t_EP,VEP); xlabel('time [sec]'); ylabel('\muV')
        title([num2str(labels(i)), ': ', num2str(labels(6-i)), ' EPs ratios,
alpha = ', num2str(alphas(j))])
    end
end

% plot of SNR as function of alpha:
figure;
noise_mat = [EP; (15*EP_2+35*EP)/50; (EP+EP_2)/2; (15*EP+35*EP_2)/50;
EP_2];
alphas = 0.0001:0.001:0.99;
SNR = zeros(1,length(alphas));
for i = 1:size(Windows,1)
    subplot(size(Windows,1),1,i)
    for j=1:length(alphas)
        VEP = Expo_avrg(Windows(i,:),alphas(j),EP_len);
        SNR(j) = snr(VEP,VEP-noise_mat(i,:));
    end
    plot(alphas,SNR); xlabel('alpha'); ylabel('SNR [dB]'); hold on
    [x,k] = max(SNR); plot(alphas(k),x,'r*')
    title(['SNR as function of alpha for ' num2str(labels(i)), ': ' ,
num2str(labels(6-i)), ' window']);
end

%% 2.3
%2.3.1
clear, clc
data = load('shani_exp2.mat');
EEG = (data.data(:,1))'; %EEG data
fs = 1000; %Hz
t = 0:1/fs:((1/fs)*(length(EEG)-1));

% plotting the EEG
figure; plot(t,EEG); xlim([0 0.2])
xlabel 'time [secs]' , ylabel '\muV', title 'EP Dan & Sol'

% filtering the power line noise using LMS
pl_ref = [sin(2*pi*50*t); cos(2*pi*50*t)];
pl_harmonic_ref = [sin(2*pi*100*t); cos(2*pi*100*t)];
[pl_clean,~] = LMS(EEG,pl_ref);
[EEG_clean,~] = LMS(pl_clean,pl_harmonic_ref);

% plotting the cleaned signal
figure; plot(t,EEG_clean); xlim([0 0.2])
xlabel 'time [secs]' , ylabel '\muV'

% Homogenous Ensemble Averaging
EP_len = fs/2;
EEG_reshaped = (reshape(EEG_clean,[EP_len, length(EEG)/EP_len]))'; %each
line contains one EP
HEA = (EP_len/length(EEG))*sum(EEG_reshaped);
% plotting the HEA
figure; plot(t(1:EP_len),HEA);
xlabel 'time [secs]' , ylabel '\muV'

```

```

%2.3.2
data2 = load('EEG_2.mat');
EEG2 = (data2.veps)';
L = length(EEG2);
fs = 500; %Hz
t = 0:1/fs:((L-1)*1/fs); %secs

EP_len2 = fs/2.5; %length of one EP

%reshaping the EEG vector to a matrix that containt one EP in each line
EEG2_resaped = (reshape(EEG2,[EP_len2, L/EP_len2]))';

%HEA calculations
HEA_5a = 1/5*sum(EEG2_resaped(1:5,:));
HEA_20a = 1/20*sum(EEG2_resaped(1:20,:));
HEA_200a = 1/200*sum(EEG2_resaped(1:200,:));
HEA_5b = 1/5*sum(EEG2_resaped(201:205,:));
HEA_20b = 1/20*sum(EEG2_resaped(201:220,:));
HEA_200b = 1/200*sum(EEG2_resaped(201:end,:));

%plotting the HEAs
figure;
subplot(231), plot(t(1:EP_len2),HEA_5a)
xlabel 'time [sec]' , ylabel '\muV' , title 'M = 5 , first part of signal'

subplot(232), plot(t(1:EP_len2),HEA_20a)
xlabel 'time [sec]' , ylabel '\muV' , title 'M = 20 , first part of signal'

subplot(233), plot(t(1:EP_len2),HEA_200a)
xlabel 'time [sec]' , ylabel '\muV' , title 'M = 200 , first part of signal'

subplot(234), plot(t(1:EP_len2),HEA_5b)
xlabel 'time [sec]' , ylabel '\muV' , title 'M = 5 , second part of signal'

subplot(235), plot(t(1:EP_len2),HEA_20b)
xlabel 'time [sec]' , ylabel '\muV' , title 'M = 20 , second part of signal'

subplot(236), plot(t(1:EP_len2),HEA_200b)
xlabel 'time [sec]' , ylabel '\muV' , title 'M = 200 , second part of signal'

%% 3.
clear, clc
data = load('Data.mat');
data = data.DATA;

%3.1
ECG = data(2,:);%wont cahnge the scale to microV because we need amplitude
similar to the signal to filter it with LMS

%resampling:
EEG = resample(data(1,:),2,1); %EEG 125Hz -> 250Hz
EOG_R = resample(data(3,:),5,1); %EOG right 50Hz -> 250Hz
EOG_L = resample(data(4,:),5,1); %EOG left 50Hz -> 250Hz

% resizing to the size of the original vector (as there is no more
% infomration in ECG vector):
EEG = EEG(1:10^5);

```

```

EOG_R = EOG_R(1:10^5);
EOG_L = EOG_L(1:10^5);
t = 0:1/250:(length(ECG)-1)/250);
figure;
subplot(411), plot(t,EEG); xlim([0 5]);
xlabel('time [sec]'); ylabel('\muV'); title('EEG')

subplot(412), plot(t,ECG); xlim([0 5]);
xlabel('time [sec]'); ylabel('mV'); title('ECG')

subplot(413), plot(t,EOG_R); xlim([0 5]);
xlabel('time [sec]'); ylabel('\muV'); title('EOG right')

subplot(414), plot(t,EOG_L); xlim([0 5]);
xlabel('time [sec]'); ylabel('\muV'); title('EOG left')

%3.2
noise_50 = 0.005*sin(2*pi*50*t); % powerline noise
EEG_noised = EEG + noise_50; %noised signal

%3.3
figure; subplot(2,1,1); plot(t,EEG); xlim([2 2.5]);
xlabel('time [sec]'); ylabel('\muV'); title('original EEG')
subplot(2,1,2); plot(t,EEG_noised); xlim([2 2.5])
xlabel('time [sec]'); ylabel('\muV'); title('EEG with noise')

%3.4
% LMS on each noise:

pl_50 = [sin(2*pi*50*t); cos(2*pi*50*t)]; %power line reference signal
[clean_pl,~] = LMS(EEG_noised,pl_50); % LMS of power line

%LMS object for ECG and EOG
lms_ob = dsp.LMSFilter('StepSize',0.01);

%LMS filtering ECG
[ECG_gain,~] = lms_ob(clean_pl',ECG');
no_ECG = clean_pl' - ECG_gain;

%LMS filtering EOG right
[EOG_gain_R,~] = lms_ob(no_ECG,EOG_R');
no_EOG_R = no_ECG - EOG_gain_R;

%LMS filtering EOG left
[EOG_gain,~] = lms_ob(no_EOG_R,EOG_L');
EEG_cleaned = no_EOG_R - EOG_gain;

figure; subplot(4,1,1); plot(t,EEG_noised); xlim([300 305])
xlabel('time [sec]'); ylabel('\muV'); title('original EEG')

subplot(4,1,2); plot(t,clean_pl); xlim([300 305])
xlabel('time [sec]'); ylabel('\muV'); title('EEG after filtering the power
line noise')

subplot(4,1,3); plot(t,no_ECG'); xlim([300 305])
xlabel('time [sec]'); ylabel('\muV'); title('EEG after filtering the ECG
signal')

```

```

subplot(4,1,4); plot(t,EEG_cleaned'); xlim([300 305])
xlabel('time [sec]'); ylabel('\muV'); title('EEG after filtering all
noises')

% original EEG and noises through all the signal:
figure;
subplot(411), plot(t,EEG);
xlabel('time [sec]'); ylabel('\muV'); title('EEG')

subplot(412), plot(t,ECG);
xlabel('time [sec]'); ylabel('mV'); title('ECG')

subplot(413), plot(t,EOG_R);
xlabel('time [sec]'); ylabel('\muV'); title('EOG right')

subplot(414), plot(t,EOG_L);
xlabel('time [sec]'); ylabel('\muV'); title('EOG left')

% 3.5
% ffts of original, filtered and reference signals:
fs = 250; %Hz
L = length(EEG);
f = linspace(-fs/2,fs/2,L);
EEG_noised_f = abs(fftshift(fft(EEG_noised))); %raw EEG fft
no_pl_f = abs(fftshift(fft(clean_pl))); % after LMS of power line fft
no_ECG_f = abs(fftshift(fft(no_ECG))); % after LMS of ECG fft
ECG_f = abs(fftshift(fft(ECG))); % ECG signal fft
EOGR_f = abs(fftshift(fft(EOG_R))); % EOG right fft
EOGL_f = abs(fftshift(fft(EOG_L))); % EOG left fft
EEG_cleaned_f = abs(fftshift(fft(EEG_cleaned'))); % after LMS of EOG, all
noises filtered
net_f = abs(fftshift(fft(noise_50))); % power line fft

%plotting these ffts:
figure;
subplot(2,4,1); plot(f,EEG_noised_f); title('original EEG fft'); ylim([0
1600])
subplot(2,4,2); plot(f,no_pl_f); title('EEG after filtering the power line
noise fft'); ylim([0 1600])
subplot(2,4,3); plot(f,no_ECG_f); title('EEG after filtering the ECG fft');
ylim([0 1600])
subplot(2,4,4); plot(f,EEG_cleaned_f); title('EEG after filtering all
noises fft'); ylim([0 1600])

subplot(2,4,5); plot(f,net_f); title('power line noise fft'); ylim([0
1600])
subplot(2,4,6); plot(f,ECG_f); title('ECG reference fft'); ylim([0 1600])
subplot(2,4,7); plot(f,EOGR_f); title('EOG right reference fft'); ylim([0
1600])
subplot(2,4,8); plot(f,EOGL_f); title('EOG left reference fft'); ylim([0
1600])

```

```

function [Clean_Signal,W] = LMS(Raw_Signal,Noise_ref,Options)
% This function recieves a raw signal and noise reference vectors and
% calculates the optimal weight vector and filters the signal using linear
% combiner filtering using these optimal weights.
%% inputs:
% Raw_Signal - the signal to be filtered
% Noise_ref - the noise reference signals
% Options - a starcture that contains initial values for the weight vector
% and step size. if one of these values isn't given it will be allocated as
% given in the function.
%% outputs:
% Clean_Signal - The filtered signal using linear combiner filter
% W - the LMS weight matrix. the last collumn is the optimal weight vector
% that can be recieved using LMS.
%%
if length(Raw_Signal)~=size(Noise_ref,2)
    error('Raw_signal and Noise_ref rows should be the same length!');
end
k = length(Raw_Signal); %number of iterations of the LMS algorithm.
R = 1/k*(Noise_ref*Noise_ref'); % the corelation matrix of the noise
reference vectors
W = zeros(size(Noise_ref,1),k); %intialization of the weight matrix
if nargin<3 % if the Options structure is missing
    mu = 1/trace(R);
elseif ~(isfield(Options,'mu')) %if the Options.mu is missing
    mu = 1/trace(R);
    W(:,1) = Options.W0;
elseif ~(isfield(Options,'W0')) %if the Options.W0 is missing
    mu = Options.mu;
    W(:,1) = 0;
else
    mu = Options.mu;
    W(:,1) = Options.W0;
end
%LMS:
for i=1:k-1
    W(:,i+1) = W(:,i) + mu*(Raw_Signal(i)-
Noise_ref(:,i)'*W(:,i)).*Noise_ref(:,i);
end
Clean_Signal = Raw_Signal-sum(W.*Noise_ref);
end

```

```

function VEP = Expo_avrg(signal,alpha,EP_length)
%% This function performs exponential averaging on the noised VEP vector -
% 'signal'
% inputs:
% signal - the vector we perform exponential averaging on
% alpha - alpha factor of the averaging that determins how to devide weight
% between recent and former EPs
% EP_length - length of one EP (length of one EP vector, not its time in
% seconds
% outputs:
% VEP - the VEP after averaging
%%

```

```

signal_resaped = (reshape(signal,[EP_length, length(signal)/EP_length]))';
%reshaping the input signal to rows of EPs to multiple each EP in its
weight decided by alpha
M = length(signal)/EP_length; %amount of EPs in signal
weights = zeros(1,M); %weight for each EP
for i=0:(M-1)
    weights(M-i) = alpha*(1-alpha)^i;
end
VEP = sum(signal_resaped.*weights'); %the exponential averaging
end

```